Pravděpodobnost a statistika KMA/PSA

Přehled definic a vět 2023/2024, část 2

8 Data a jejich vizualizace **3**

8.1 Data . . . 3

8.2 Deskriptivní (popisná) statistika . . . 4

8.2.1 Míry polohy . . . 4

8.2.2 Míry variability . . . 5

8.3 Vizualizační nástroje . . . 6

8.4 Histogram . . . 7

8.5 Boxplot . . . 9

8.6 Empirická distribuční funkce . . . 10

8.7 Probability plot . . . 11

9 Náhodný výběr. Bodové a intervalové odhady **12**

9.1 Náhodný výběr a výběrové charakteristiky . . . 12

9.2 Bodové odhady . . . 13

9.3 Intervalové odhady . . . 14

10 Testování statistických hypotéz **15**

10.1 Formulace statistických hypotéz . . . 15

10.2 Chyby I. a II. druhu u statistických testů a p-hodnota testu . . . 15

10.3 Jednovýběrové parametrické testy . . . 16

10.3.1 Test o střední hodnotě při známém rozptylu. . . Z-test . . . 16

10.3.2 Test o střední hodnotě při neznámém rozptylu. . . T-test . . . 16

10.3.3 Test o rozptylu . . . 16

10.4 Dvouvýběrové parametrické testy . . . 17

10.4.1 Test o shodě středních hodnot - T-test . . . 17

10.4.2 Test o shodě rozptylů - F-test . . . 17

10.4.3 Test o koeficientu korelace (lineární závislosti) . . . 17

10.5 Testování shody dat s modelem . . . 18

10.5.1 χ^2 test dobré shody . . . 18

10.5.2 Kontingenční tabulky. Testování nezávislosti . . . 19

11 Regresní analýza **20**

11.1 Lineární regresní model . . . 20

11.2 Metoda nejmenších čtverců . . . 21

11.3 Testy pro lineární regresní modely . . . 22

RNDr. Blanka Šedivá, Ph.D.

v Plzni dne 4. ledna 2024

Statistika je věda a postup jak rozvíjet lidské znalosti použitím empirických dat. Zaměřuje se na hromadně se opakující situace, které jsou zatíženy náhodnými vlivy a soustřeďuje se jak na jejich společné vlastnosti, tak na identifikaci rozdílných charakteristik.
Statistický soubor je nějaký dobře definovaný soubor statistických jednotek. Musíme být schopni ověřit, zda statistická jednotka do souboru patří.
Statistická jednotka je prvek statistického souboru, u kterého měříme jeden nebo více statistických znaků (proměnných).
Populace (základní soubor) je soubor objektů (statistických jednotek), který je vymezen jejich výčtem nebo charakterizací jejich vlastností, může být proto konečný i nekonečný.
Výběr je konečná podmnožina populace, kdy sledujeme a měříme požadované vlastnosti pouze u některých prvků populace. Výběr je vždy konečný (rozsah označujeme n)
Podle charakteru získávání výběru prvků z populace rozlišujeme

- úplné šetření: sledujeme znaky všech prvků základního souboru;
- záměrný (selektivní výběr): výběr se opírá o expertní stanoviska nebo je ovlivněn subjektivními hledisky experimentátora,
- randomizovaný výběr: prvky ze základního souboru vybíráme nezávisle na úsudku experimentátora
  - prostý náhodný výběr (simple random sample)
  - mechanický výběr: je založen na určitém, předem daném uspořádání prvků populace, do výběrového souboru zařadíme všechny prvky, které jsou od sebe vzdáleny o zvolený výběrový krok, přičemž první prvek vybereme prostým náhodným výběrem.
  - oblastní výběr (stratifikovaný): studovaná populace je rozdělena do dílčích oblastí. Oblasti jsou vytvořeny tak, aby byly uvnitř homogenní (ve sledovaných znacích se příliš neliší) a mezi sebou heterogenní (sledované znaky se značně liší). Z každé oblasti vybereme vzorek metodou prostého náhodného výběru nebo mechanického výběru.
  - skupinový výběr: Pro velké rozsahy populace neprovádíme náhodný výběr, tj. nevybíráme jednotlivé osoby, nýbrž celé skupiny osob, které tvoří buď přirozené nebo umělé agregáty. Tyto skupiny mohou být malé i větší (rodina, škola, závod, zdravotní obvod) nebo i značně rozsáhlé (obce, okresy). Je žádoucí, aby skupiny byly pokud možno stejně velké a osoby uvnitř každé skupiny různorodé. Dále se požaduje, aby variabilita mezi skupinami byla co nejmenší, což je tedy obráceně, než je tomu u oblastního výběru. Když byl proveden výběr skupin, lze dále pokračovat dvojím způsobem: buď vyšetříme vyčerpávajícím způsobem všechny osoby vybraných skupin, nebo zvolíme metodu vícestupňového výběru.
  - vícestupňový výběr: je založen na existenci určitého hierarchického popisu prvků základního souboru. K těmto prvkům se postupně dostáváme přes vyšší výběrové jednotky, například: města - bloky - domy - domácnosti; okresy - závody - dílny - zaměstnanci.
- cenzorovaný výběr je výběr, kdy nemáme k dispozici přesnou hodnotu sledované charakteristiky, ale máme informaci, že hodnota bude větší než konkrétní číslo (cenzorování zprava) nebo menší než konkrétní číslo (cenzorování zleva), například sleduje dobu přežití a v okamžiku ukončení experimentu víme, že pacient přežil více než 5 let, ale nevíme přesnou dobu přežití.

8 Data a jejich vizualizace

8.1 Data

Datový soubor (data) je souhrn údajů příslušných k jednotlivým statistickým jednotkám. Rozsah souboru (n) odpovídá počtu sledovaných statistických jednotek a dimense proměnných (k) odpovídá počtu sledovaných statistických znaků.

kvalitativní nominální binární data (alternativní, dichotomická) - data nabývají pouze dvou hodnot typu ANO - NE nebo 0-1;

kvalitativní nominální data (víceškálové) - (kategoriální data) data mají původně slovní charakter, při přiřazování číselných charakteristik nelze „rozumným způsobem“ zavést do dat uspořádání, typickým případem jsou data vyjadřující např. bydliště, různé barvy sledovaného objektu a podobně;

kvalitativní ordinální data - data mají původně slovní charakter a při převodu do číselné škály je přirozeným způsobem zavedeno uspořádání, například maximální dosažené vzdělání, hodnocení známkami, vyjádření užitečnosti a podobně;

kvantitativní diskrétní data - intervalová stupnice data mají přirozenou číselnou charakteristiku, čísla zároveň vyjadřují uspořádání v námi zvoleném smyslu, zároveň se můžeme ptát „o kolik“ je jeden znak lepší než druhý, svůj praktický význam má tedy i veličina $x_i - x_j$, v rámci intervalové stupnice má „nulová hodnota“ pouze relativní charakter, například nulová teplota;

kvantitativní diskrétní data - poměrová stupnice data mají přirozenou číselnou charakteristiku, čísla zároveň vyjadřují uspořádání v námi zvoleném smyslu, zároveň se můžeme ptát „kolikrát“ je hodnota jednoho znaku jiná (lepší) než hodnota druhého znaku, svůj praktický význam má tedy i veličina $\frac{x_i}{x_j}$, v rámci poměrové stupnice má konkrétní význam „nulová hodnota“, například nulová hmotnost, nulová rychlost, nulový počet výskytu sledovaného jevu;

kvantitativní spojitá data - data mají přirozenou číselnou charakteristiku, ale tato charakteristika může nabývat nekonečného počtu hodnot, nejčastěji vznikají tato data měřením a vážením objektů, zachycením času a podobě;

data s neúplnou informací - do této kategorie spadají data, o kterých víme například pouze to, zda jsou pod detekčním limitem, ev. data cenzorovaná časem, ev. data mající intervalový charakter (víme pouze to, že hodnota proměnné leží v intervalu) a podobně.

8.2 Deskriptivní (popisná) statistika

Předpokládáme, že máme k dispozici data - budeme značit $x_1, x_2, \ldots, x_n$, v případě, že data budou uspořádána podle velikosti, zdůrazníme toto značením $x_{(1)}, x_{(2)}, \ldots, x_{(n)}$. V takovémto případě pak platí $x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}$, kde hodnota $x_{(1)}$ je minimální hodnota dat a hodnota $x_{(n)}$ je maximální hodnota dat.
Charakteristiky datového souboru, nazývané též popisné (deskriptivní) míry dat jsou čísla spočtená z dat.

8.2.1 Míry polohy

Průměry jsou vhodné pro kvantitativní typ dat:

Aritmetický průměr $\overline{x} = \dfrac{x_1 + x_2 + \cdots + x_n}{n}$ (invariantní vůči lineární transformaci, citlivý na odlehlé hodnoty).

Geometrický průměr (má smysl pouze pro kladné hodnoty) $\overline{x}_G = \sqrt[n]{x_1 \cdot x_2 \cdot \cdots \cdot x_n}$, vhodný např. pro procentuální změny.

Harmonický průměr (má smysl pouze pro kladné hodnoty) $\overline{x}_H = \left(\dfrac{1}{n}\displaystyle\sum_{i=1}^{n}\left(\dfrac{1}{x_i}\right)\right)^{-1}$, vhodný např. pro průměrnou rychlost nebo poměrové veličiny.

$$\overline{x}_H \leq \overline{x}_G \leq \overline{x}$$

Medián je taková hodnota, že v případě, že uspořádáme data podle velikosti, je přesně polovina hodnot menší než medián $\widetilde{x}$ a polovina hodnot je větší než medián.

$$\widetilde{x} = \begin{cases} x_{\left(\frac{n+1}{2}\right)} & n \text{ liché} \\ \frac{1}{2}\left(x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}\right) & n \text{ sudé} \end{cases}$$

Výběrové kvantily (percentily) α-procentní kvantil Q_α je taková hodnota, že v případě, že uspořádáme data podle velikosti, je α procent hodnot menší než kvantil Q_α a $100-\alpha$ procent hodnot je větší než kvantil. Hodnotu Q_{25} nazýváme dolní kvartil, hodnota Q_{50} je medián, hodnotu Q_{75} nazýváme horní kvartil, analogicky hodnoty Q_{10} resp.Q_{90} a Q_1 resp. Q_{99} nazýváme dolní (horní) decil a dolní (horní) percil.

Modus nejčetnější hodnota, tj. hodnota, která se v souboru dat opakuje nejvícekrát, tato charakteristika nemá významnější uplatnění a poskytuje nám pouze doplňkové informace o souboru dat.

8.2.2 Míry variability

Rozptyl (populační rozptyl) $s_P^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2$.

Výběrový rozptyl $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})^2 = \frac{1}{n-1}\left(\sum_{i=1}^{n} x_i^2 - n\overline{x}^2\right)$.

Výběrová směrodatná odchylka $s = \sqrt{s^2}$.

Výběrový variační koeficient $v = \frac{s}{\overline{x}}$.

Rozpětí $R = Q_{100} - Q_0 = x_{(n)} - x_{(1)} = max(x) - min(x)$.

Kvartilové rozpětí $R_Q = Q_{75} - Q_{25}$. Obdobně je definováno decilové rozpětí $R_D = Q_{90} - Q_{10}$.

Průměrná absolutní odchylka od mediánu $d_{\widetilde{x}} = \frac{1}{n}\sum_{i=1}^{n}|x_i - \widetilde{x}|$.

Statistická entropie (Claude Shannon) vhodná charakteristika zejména pro kvalitativní data, využitelné v teorii informací $H = -\sum_{j=1}^{m}\frac{n_j}{n}\cdot\log_b\left(\frac{n_j}{n}\right)$, kde $n_1, n_2, \ldots$ jsou zjištěné nenulové četnosti jednotlivých hodnot měřené veličiny. Entropie je pro $b = 2$ vyjádřena v bitech, pro $b = e$ v jednotkách nazývaných nat a pro $b = 10$ v jednotkách nazývaných ban, hartley nebo dit. Entropii lze normalizovat tím, že ji vydělíme délkou informace. Výsledný poměr se nazývá metrika entropie a je mírou náhodnosti informace.

Věta 8.1. *Funkce* $S(t) = \frac{1}{n}\sum_{i=1}^{n}(x_i - t)^2$ *nabývá svého minima, právě tehdy, když* $t = \overline{x}$.

Funkce $T(t) = \frac{1}{n}\sum_{i=1}^{n}|x_i - t|$ *nabývá svého minima, právě tehdy, když* $t = \widetilde{x}$.

Věta 8.2. *Entropie je maximální právě tehdy, když* $\frac{n_1}{n} = \frac{n_2}{n} = \cdots = \frac{n_m}{n}$.

8.3 Vizualizační nástroje

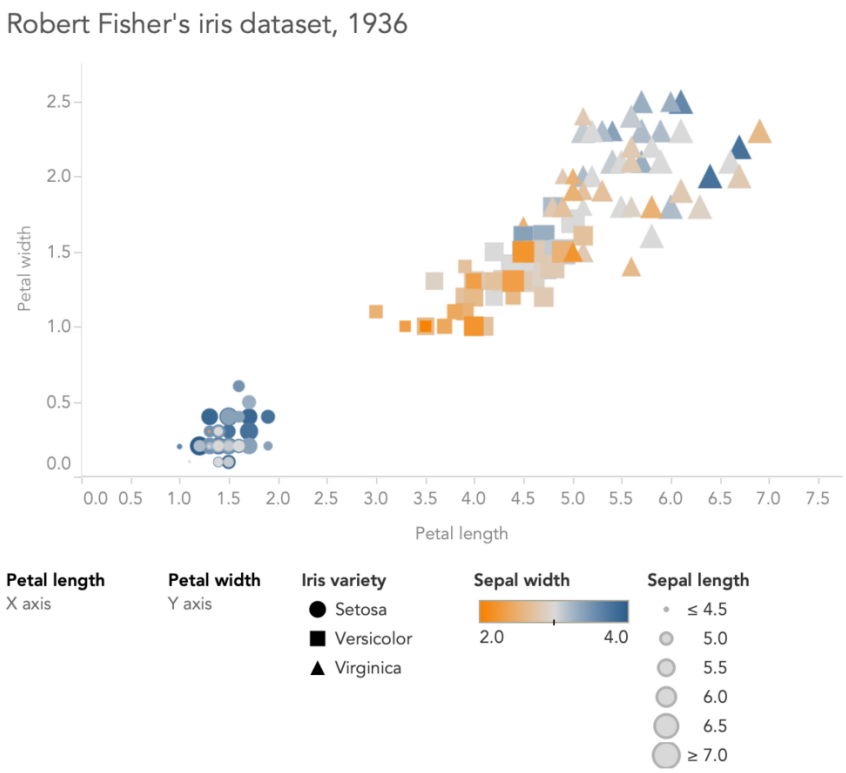

https://www.storytellingwithdata.com/blog/2021/11/5/how-do-i-graph-three-or-more-dimensions

Matplotlib: Jedna z nejběžněji používaných knihoven pro vizualizaci dat v jazyce Python. Obsahuje širokou škálu funkcí pro tvorbu různých typů grafů, včetně histogramů, scatter plotů, čárových grafů, koláčových grafů, violin plotů a mnoho dalších. https://matplotlib.org/stable/contents.html

Seaborn: Další knihovna pro vizualizaci dat v jazyce Python, která je postavena na Matplotlib. Seaborn poskytuje jednodušší a výraznější rozhraní pro tvorbu různých statistických grafů, jako jsou violin ploty, box ploty, rozptylové diagramy a další. https://seaborn.pydata.org/

Plotly: Interaktivní knihovna pro vizualizaci dat v jazyce Python, R a dalších jazycích. Plotly poskytuje možnost vytvářet různé interaktivní grafy, včetně histogramů, scatter plotů, čárových grafů, koláčových grafů, heatmap a mnoho dalších. https://plotly.com/

ggplot2: Knihovna pro vizualizaci dat v jazyce R, která je založena na konceptu "gramatiky grafů"a umožňuje snadné vytváření různých typů grafů, včetně histogramů, scatter plotů, čárových grafů, koláčových grafů, box plotů a mnoho dalších. https://ggplot2.tidyverse.org/

8.4 Histogram

Metody určování délky tříd h, resp. počtu tříd k:

- Sturgesovo pravidlo - $h = \frac{R}{k}$, kde R je $x_{max} - x_{min}$ a $k = 1 + \log_2 n$;
- Modifikované Sturgesovo pravidlo - $k = 1 + 3.3 \cdot \ln n$;
- Scottovo pravidlo - $h = 3.5 \cdot \frac{s}{n^{1/3}}$, kde s je výběrová směrodatná odchylka;
- Freedman, Diaconisovo pravidlo - $h = 2 \cdot \frac{R_Q}{n^{1/3}}$, kde $R_Q = Q_{75} - Q_{25}$ je kvartilové rozpětí ;

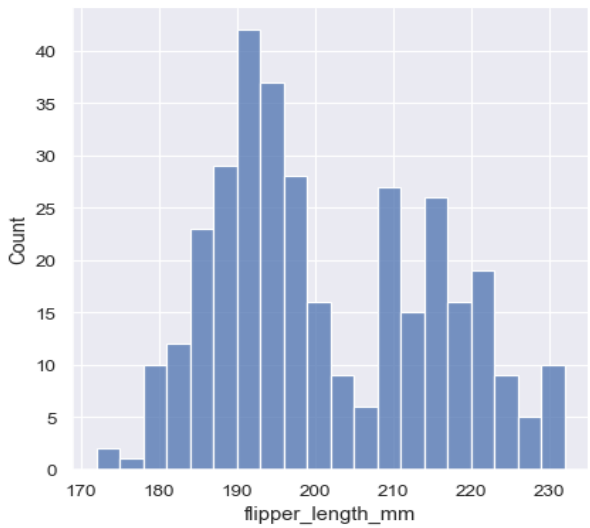

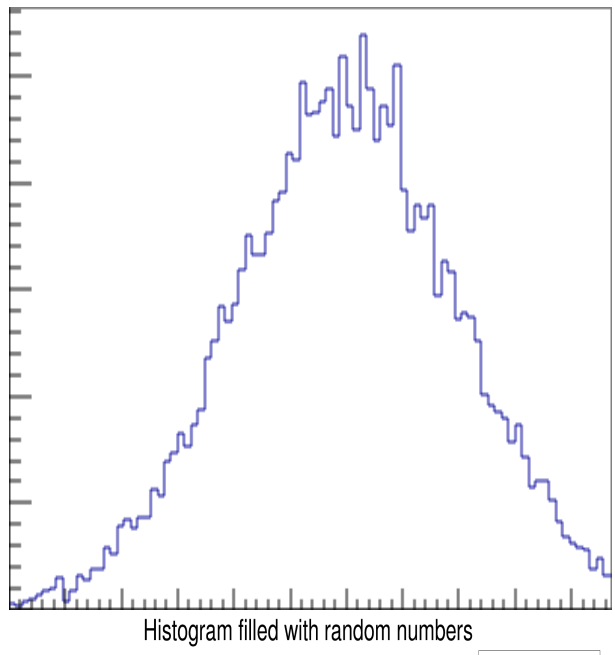

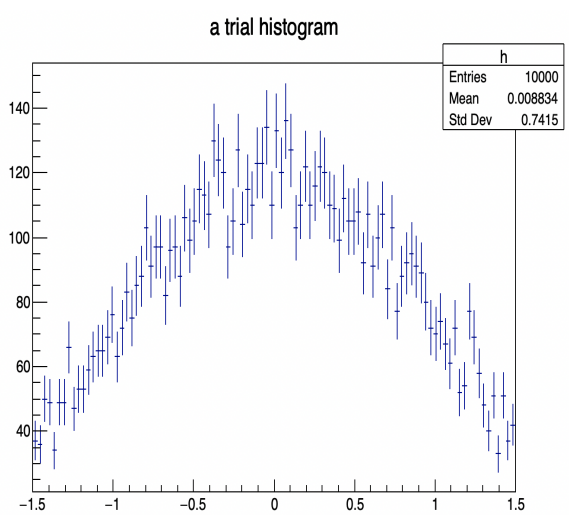

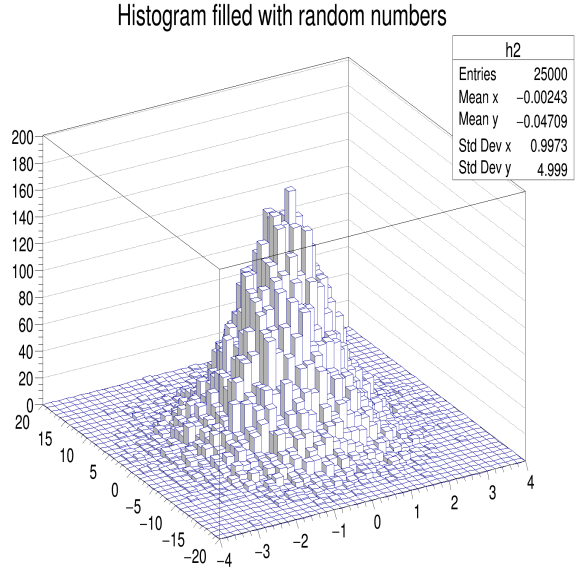

Jádrové histogramy (kernel)

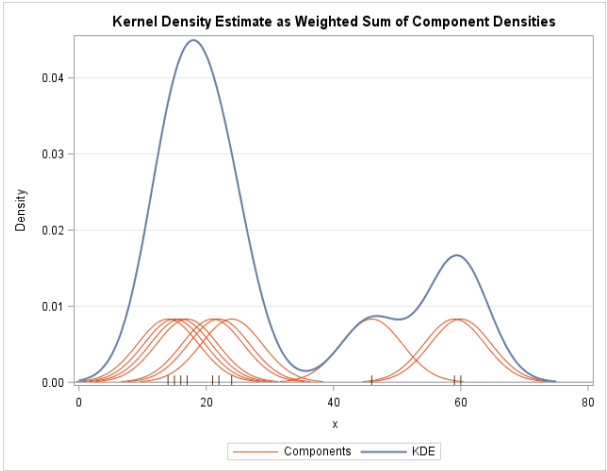

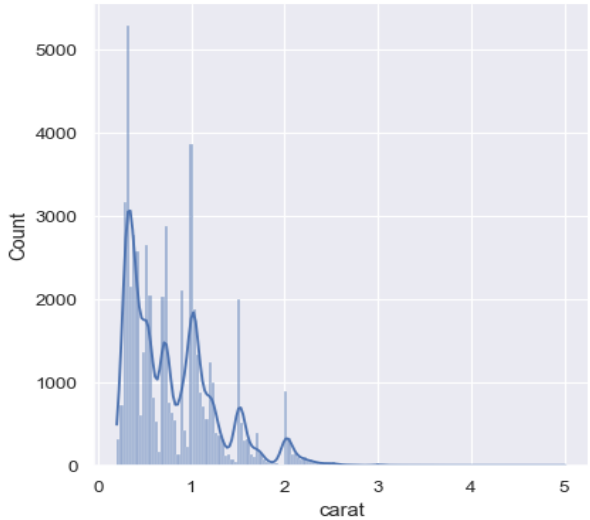

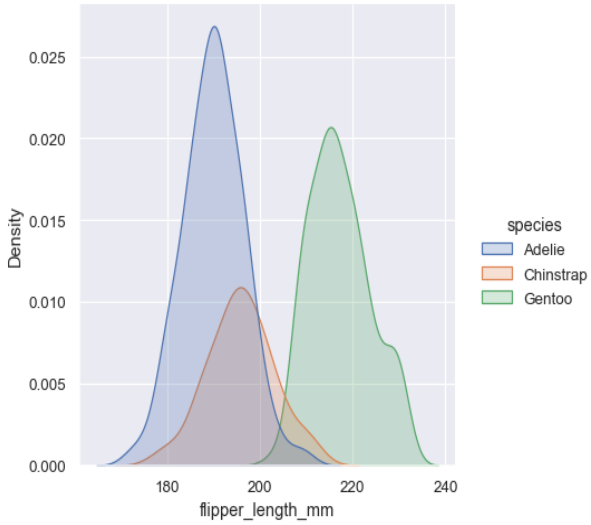

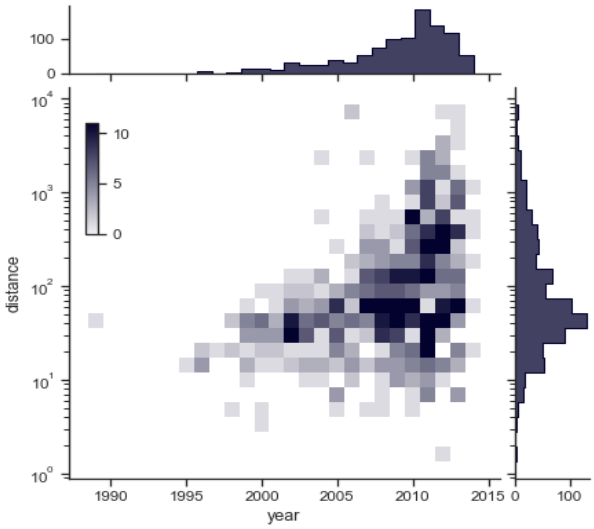

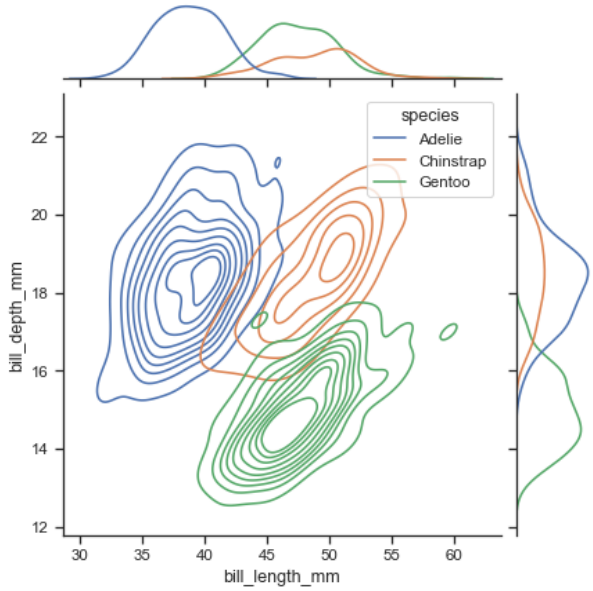

8.5 Boxplot

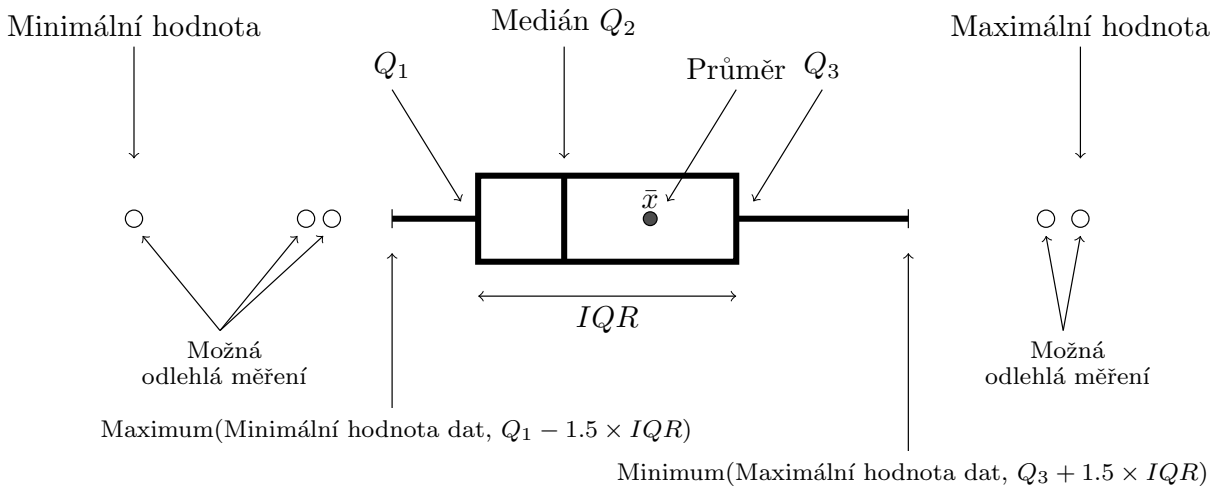
Minimální hodnota
Medián Q_2
Maximální hodnota
Q_1
Průměr
Q_3
$\bar{x}$
IQR
Možná
odlehlá měření
Možná
odlehlá měření
Maximum(Minimální hodnota dat, $Q_1 - 1.5 \times IQR$)
Minimum(Maximální hodnota dat, $Q_3 + 1.5 \times IQR$)

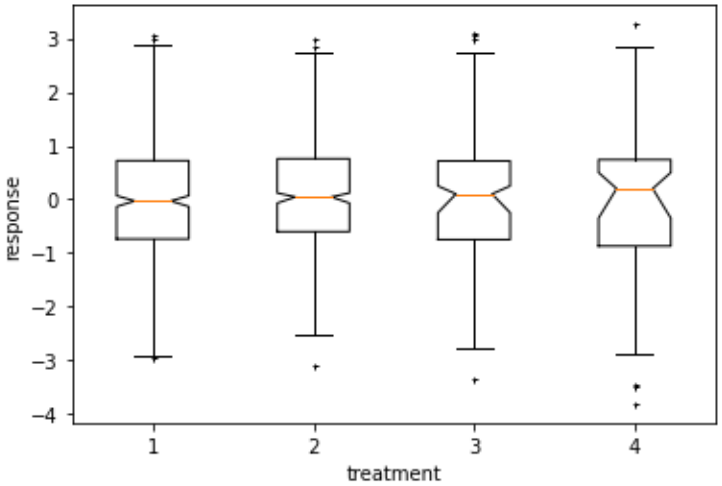
response
treatment

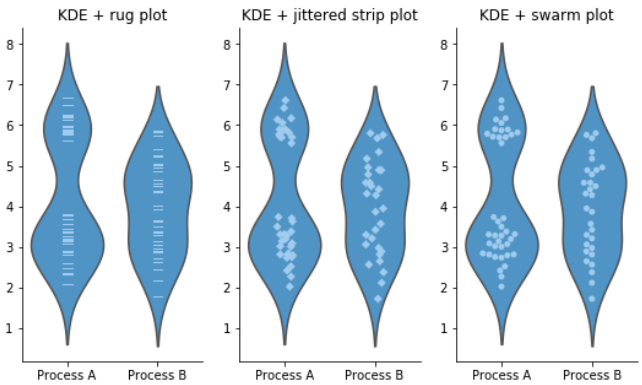
KDE + rug plot
KDE + jittered strip plot
KDE + swarm plot
Process A
Process B

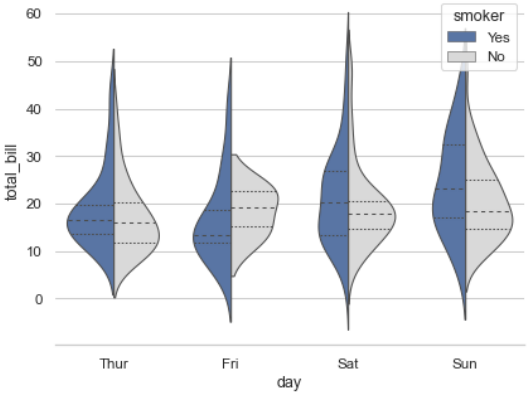
smoker
Yes
No
total_bill
Thur
Fri
Sat
Sun
day

8.6 Empirická distribuční funkce

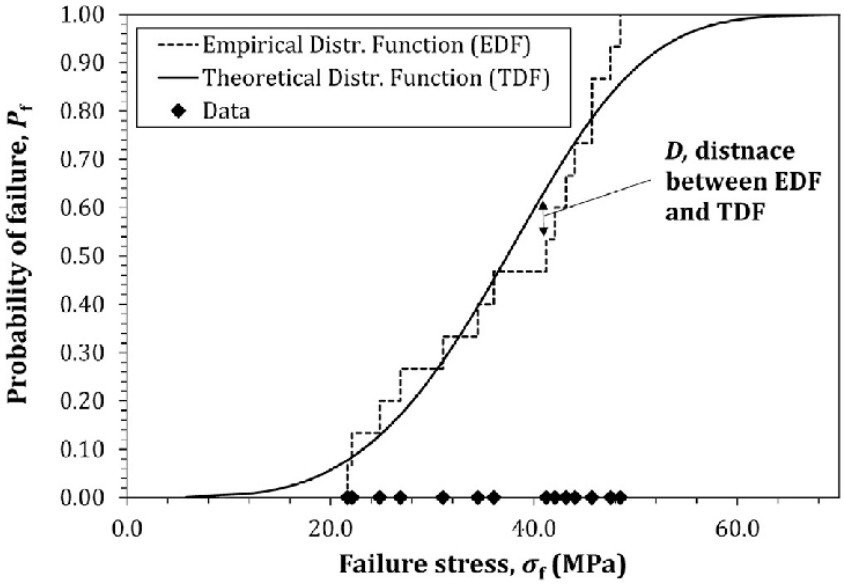

8.7 Probability plot

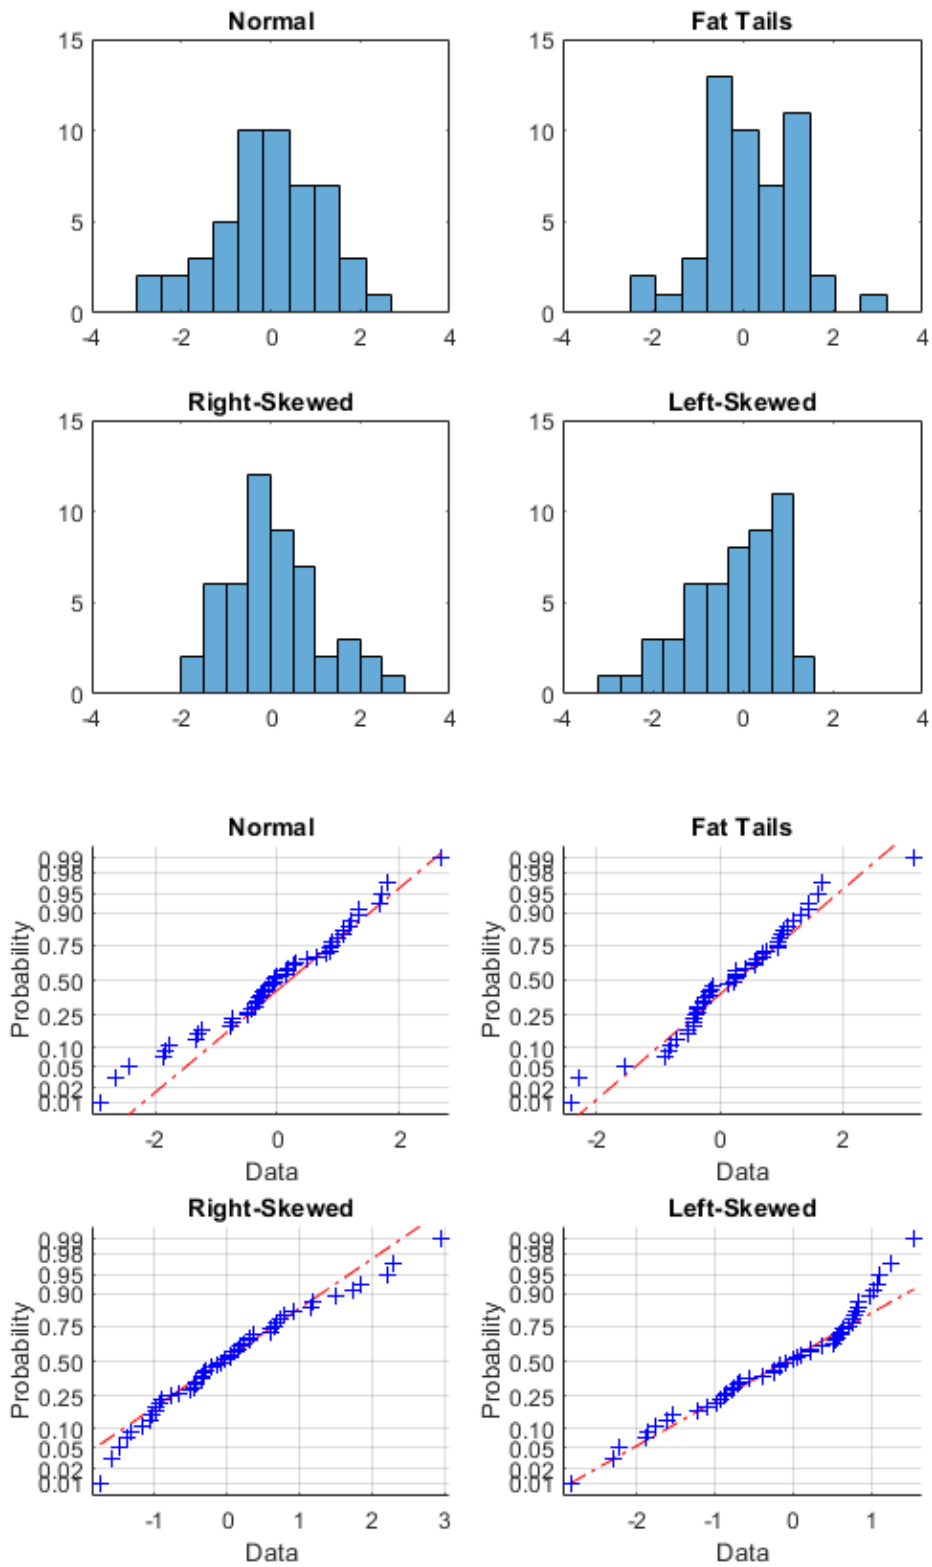

9 Náhodný výběr. Bodové a intervalové odhady

9.1 Náhodný výběr a výběrové charakteristiky

Definice 9.1 (Náhodný výběr)**.** *Vektor $X_1, X_2, \ldots, X_n$ složený z n nezávislých stejně rozdělených náhodných veličin (i.i.d. - independent identically distributed) nazýváme náhodný výběr rozsahu n.*

Náhodné veličiny X_i jsou popsány distribuční funkcí (případně funkcí hustoty nebo pravděpodobnostní funkcí) s parametry $\mathbf{\Theta} = (\Theta_1, \Theta_2, \ldots, \Theta_k)$, tedy $X_i \sim F(\Theta_1, \Theta_2, \ldots, \Theta_k)$.
Střední hodnotu veličin budeme značit $\mu(\mathbf{\Theta})$, kde $\mathbf{\Theta}$ jsou parametry daného rozdělení a rozptyl budeme značit $\sigma^2(\mathbf{\Theta})$.

Realizace náhodného výběru $x_1, x_2, \ldots, x_n$ tvoří datový soubor.
Náhodný výběr a datový soubor lze popsat pomocí charakteristik. Charakteristiky jsou funkce výběru $X_1, X_2, \ldots$, resp. funkce hodnot datového souboru.

Definice 9.2 (Statistika)**.** *Libovolnou náhodnou veličinu T_n, která vznikne jako funkce náhodného výběru $X_1, X_2, \ldots, X_n$ nazýváme statistikou, tj. $T_n = T(X_1, X_2, \ldots, X_n)$.*

Definice 9.3 (Výběrové charakteristiky)**.** *Nechť $X_1, X_2, \ldots, X_n$ je náhodný výběr rozsahu n z rozdělení s distribuční funkcí $F(x; \mathbf{\Theta})$. Pak statistika*

$\overline{X_n} = \dfrac{1}{n}\sum_{i=1}^{n} X_i,$	*se nazývá*	*výběrový průměr;*
$s_n^2 = \dfrac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X_n}\right)^2$		*výběrový rozptyl;*
$s_n = \sqrt{s_n^2}$		*výběrová směrodatná odchylka.*

Věta 9.4 (Střední hodnota a rozptyl výběrového průměru a rozptylu)**.** *Nechť $X_1, X_2, \ldots, X_n$ je náhodný výběr rozsahu n z rozdělení se střední hodnotou $\mu = \mu(\mathbf{\Theta})$ a rozptylem $\sigma^2 = \sigma^2(\mathbf{\Theta})$. Pak*

(i) *pro výběrový průměr platí, že střední hodnota je $\mathbb{E}[\overline{X_n}] = \mu$ a rozptyl je $\mathrm{var}[\overline{\mathrm{X_n}}] = \dfrac{\sigma^2}{\mathrm{n}}$*

(ii) *pro výběrový rozptyl platí, že střední hodnota je $\mathbb{E}[s_n^2] = \sigma^2$ a rozptyl je $\mathrm{var}[\mathrm{s_n^2}] = \dfrac{\mu_4}{\mathrm{n}} - \dfrac{\sigma^4(\mathrm{n}-3)}{\mathrm{n}(\mathrm{n}-1)}$,*
kde μ_4 je čtvrtý centrální moment $\mu_4 = \mathbb{E}[(X-\mu)^4]$.

Věta 9.5 (Rozdělení výběrových charakteristik)**.** *Pro náhodný výběr rozsahu n z normálního rozdělení $X \sim N(\mu, \sigma^2)$ platí*

$\overline{X}_n = 1/n \sum_{i=1}^{n} X_i$	*má rozdělení*	$N\left(\mu, \sigma^2/n\right)$	*normální*
$Z = \dfrac{\overline{X_n} - \mu}{\sigma}\sqrt{n}$		$N(0,1)$	*normální*
$t = \dfrac{\overline{X_n} - \mu}{s_n}\sqrt{n}$		$t(n-1)$	*Studentovo t-rozdělení se stup. volnosti* $\nu = n-1$
$\dfrac{(n-1)s_n^2}{\sigma^2}$		$\chi^2(n-1)$	χ^2*rozdělení se stupněm volnosti* $\nu = n-1$

9.2 Bodové odhady

Definice 9.6 (Bodový odhad)**.** *Uvažujme náhodnou veličinu X s funkcí hustoty $f(x;\theta)$ s neznámým parametrem θ.*
Pak bodovým odhadem parametru θ rozumíme jakoukoliv statistiku (funkci) ${}_\theta T_n = T(X_1, X_2, \ldots, X_n)$, která nezávisí na θ.
Pak bodový odhad parametru θ založený na statistice ${}_\theta T_n$ a dané realizaci výběru je hodnota statistiky T s dosazenou realizací $\mathbf{x}$ a značíme

$$\widehat{\theta} = {}_\theta T_n(\mathbf{x}).$$

Definice 9.7 (Vlastnosti odhadů)**.** .

(i) *Statistika $T = {}_\theta T_n$ poskytuje **nestranný odhad**, pokud platí $\mathbb{E}[T(X_1, X_2, \ldots, X_n)] = \theta$ pro všechny možné hodnoty θ.*

Vychýlení odhadu $Bias[{}_\theta T_n]$ je rozdíl mezi střední hodnotou odhadu a odhadovaným parametrem $Bias[{}_\theta T_n] = \mathbb{E}[{}_\theta T_n(X_1, X_2, \ldots, X_n)] - \theta$

Střední kvadratická chyba odhadu je $MSE({}_\theta T_n) = \mathbb{E}\left({}_\theta T_n - \theta\right)^2 = \mathrm{var}[{}_\theta \mathrm{T_n}] - (\mathrm{Bias}[{}_\theta \mathrm{T_n}])^2$

(ii) *Statistika T poskytuje **konzistentní odhad**, pokud s rostoucím n „zpřesňujeme odhad“, tj.*

$$\lim_{n\to\infty} P\left(|{}_\theta T_n - \theta| < \varepsilon\right) = 1$$

pro všechny možné hodnoty θ.

(iii) *Statistika ${}_\theta T_n$ poskytuje **lepší odhad** než statistika ${}_\theta U_n$, pokud*

$$\mathrm{var}[{}_\theta \mathrm{T_n}] < \mathrm{var}[{}_\theta \mathrm{U_n}]$$

pro všechny možné hodnoty θ.

(pro vychýlené odhady porovnáváme vydatnost pomocí $MSE(T) < MSE(U)$.)

Věta 9.8. *Nechť statistika ${}_\theta T_n$ je nestranný nebo asymptoticky nestranný odhad parametru θ a platí*

$$\lim_{n\to\infty} \mathrm{var}[{}_\theta \mathrm{T_n}] = 0$$

Pak statistika ${}_\theta T_n$ je konzistentním odhadem parametru θ.

Metody konstrukce bodových odhadů

momentová metoda porovnává momenty náhodné veličiny a výběrové momenty

metoda maximální věrohodnosti je založena na maximalizaci věrohodnostní funkce L, kde tato funkce pro náhodný výběr má tvar

$$L(\theta) = \prod_{i=1}^{n} f(x_i;\theta) = f(x_1;\theta)\cdot f(x_2;\theta)\cdot\dots\cdot f(x_n;\theta)$$

9.3 Intervalové odhady

Definice 9.9 (Intervalový odhad parametru θ)**.** *Platí-li pro statistiky $D = D(X_1, X_2, \dots, X_n)$ a $H = H(X_1, X_2, \dots, X_n)$ vztah*

$$P(D \le \theta \le H) = 1 - \alpha,$$

říkáme, že $(D; H)$ je intervalovým odhadem parametru θ s koeficientem spolehlivostí $1-\alpha$. Intervaly tvaru $(D; H)$ se nazývají dvoustranné, tvaru $(-\infty; H)$, resp. $(D; +\infty)$ se nazývají jednostranné. Přesnost odhadu je dána šířkou dvoustranného intervalu $|H - D|$.

Vybrané intervalové odhady parametrů θ ve tvaru $(D; H)$ se spolehlivostí $1-\alpha$ mají následující tvar

- Pro parametr μ normálního rozdělení (pro známý rozptyl σ^2) $\bar{x} \pm u_{1-\frac{\alpha}{2}} \cdot \dfrac{\sigma}{\sqrt{n}}$
- Pro parametr μ normálního rozdělení (pro neznámý rozptyl) $\bar{x} \pm t_{1-\frac{\alpha}{2}}(\nu = n-1) \cdot \dfrac{s}{\sqrt{n}}$
- Pro parametr σ^2 normálního rozdělení $\left(\dfrac{(n-1)s^2}{\chi^2_{1-\frac{\alpha}{2}}(\nu = n-1)}; \dfrac{(n-1)s^2}{\chi^2_{\frac{\alpha}{2}}(\nu = n-1)}\right)$
- Pro parametr p alternativního rozdělení $\hat{p} \pm u_{1-\frac{\alpha}{2}} \cdot \sqrt{\dfrac{\hat{p}(1-\hat{p})}{n}}$

10 Testování statistických hypotéz

10.1 Formulace statistických hypotéz

- na základě realizace náhodného výběru $X_1, X_2, \ldots, X_n$ rozsahu n ověřujeme určitou hypotézu týkající se náhodné veličiny X
- statistická hypotéza je určité tvrzení
  - o parametrech (parametrické testy) pozorované náhodné veličiny pocházející se základního souboru
  - nebo o tvaru rozdělení znaku v základním souboru (neparametrické testy) na základě pozorované náhodné veličiny
- testování statistických hypotéz je jednoduchý rozhodovací postup, při němž se na základě výsledků získaných náhodným výběrem vyslovíme buď pro testovanou (nulovou) hypotézu nebo pro alternativní hypotézu

Definice 10.1 (Statistické testování)**.** *Předpokládáme, že $X_1, X_2, \ldots, X_n$ je náhodný výběr z rozdělení s distribuční funkcí $F_\theta, \theta \in \Theta$. Dále předpokládáme, že o parametru θ existují dvě konkurující si hypotézy H_0 je $\theta \in \Theta_0$ a H_1 je $\theta \in \Theta - \Theta_0$. Testem rozumíme rozhodovací postup, který nám na základě realizace náhodného výběru umožní zamítnout nebo nezamítnout platnost hypotézy H_0.*

10.2 Chyby I. a II. druhu u statistických testů a p-hodnota testu

$\ddots$ Skutečnost Úsudek o H_0	H_0 je pravdivá	H_0 je nepravdivá
nezamítá se H_0	správné rozhodnutí $P = 1 - \alpha$	chyba II. druhu $P = \beta$
zamítá se H_0	chyba I. druhu $P = \alpha$	správné rozhodnutí $P = 1 - \beta$

Rozhodovací algoritmus testů

- **testová statistika** je statistika vypočtená z náhodného výběru $T = T(X_1, X_2, \ldots, X_n)$,
- statistické rozhodování probíhá na základě **kritického oboru** W, kdy kritický obor volíme tak, aby při platnosti H_1 hodnota testové statistiky padla do kritického oboru co možná nejčastěji a při platnosti H_0 zřídka,

  pokud $T \in W \rightarrow$ zamítám nulovou hypotézu a pokud $T \notin W \rightarrow$ nezamítám nulovou hypotézu
- velikost W volíme tak, abychom platnou hypotézu H_0 zamítali nejvýše s pravděpodobností α - jedná se maximální povolenou chybu I. druhu a nazýváme ji **hladina testu**

  volíme obvykle α= 5% (případně 1%,nebo 10%)

- výpočetní sw poskytují informaci o nejmenší hladině, při které bychom hypotézu H_0 zamítli, tato nejmenší hladina se nazývá **p-hodnota testu**

  p-hodnota testu udává mezní hodnotu hladiny významnosti, při které zamítáme H_0

  H_0 zamítáme na hladině α právě tehdy, když hodnota $p < \alpha$

  nízké p-hodnoty $\rightarrow$ zamítám nulovou hypotézu, vysoké p-hodnoty $\rightarrow$ nezamítám nulovou hypotézu

10.3 Jednovýběrové parametrické testy

10.3.1 Test o střední hodnotě při známém rozptylu... Z-test

Pokud $X_1, X_2, \ldots, X_n$ je náhodný výběr z normálního rozdělení se známým rozptylem σ^2

nulová hypotéza H_0	alternativní H_1	testová statistika $T(X_1, X_2, \ldots, X_n)$	kritický obor $T(X_1, X_2, \ldots, X_n) \in W$
$\mu = \mu_0$	$\mu \neq \mu_0$	$U = \dfrac{\overline{x} - \mu_0}{\sigma}\sqrt{n}$	$\lvert U \rvert > u_{1-\alpha/2}$
	$\mu > \mu_0$		$U > u_{1-\alpha}$
	$\mu < \mu_0$		$U < -u_{1-\alpha}$

10.3.2 Test o střední hodnotě při neznámém rozptylu... T-test

Pokud $X_1, X_2, \ldots, X_n$ je náhodný výběr z normálního rozdělení s neznámým rozptylem

nulová hypotéza H_0	alternativní H_1	testová statistika $T(X_1, X_2, \ldots, X_n)$	kritický obor $T(X_1, X_2, \ldots, X_n) \in W$
$\mu = \mu_0$	$\mu \neq \mu_0$	$T = \dfrac{\overline{x} - \mu_0}{s}\sqrt{n}$	$\lvert T \rvert > t_{1-\alpha/2}(\nu = n-1)$
	$\mu > \mu_0$		$T > t_{1-\alpha}(\nu = n-1)$
	$\mu < \mu_0$		$T < -t_{1-\alpha}(\nu = n-1)$

10.3.3 Test o rozptylu

Pokud $X_1, X_2, \ldots, X_n$ je náhodný výběr z normálního rozdělení s neznámou střední hodnotou

nulová hypotéza H_0	alternativní H_1	testová statistika $T(X_1, X_2, \ldots, X_n)$	kritický obor $T(X_1, X_2, \ldots, X_n) \in W$
$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$T = \dfrac{(n-1)s^2}{\sigma_0^2}$	$T \notin \left(\chi^2_{\alpha/2}(\nu = n-1); \chi^2_{1-\alpha/2}(\nu = n-1)\right)$
	$\sigma^2 > \sigma_0^2$		$T > \chi^2_{1-\alpha}(\nu = n-1)$
	$\sigma^2 < \sigma_0^2$		$T < \chi^2_{\alpha}(\nu = n-1)$

10.4 Dvouvýběrové parametrické testy

10.4.1 Test o shodě středních hodnot - T-test

Pokud $X_1, X_2, \ldots, X_{n_1}$ je náhodný výběr z normálního rozdělení $N(\mu_1, \sigma^2)$ a $Y_1, Y_2, \ldots, Y_{n_2}$ je na něm nezávislý náhodný výběr z normálního rozdělení $N(\mu_2, \sigma^2)$

nulová hypotéza H_0	alternativní H_1	testová statistika T	kritický obor $T \in W$
$\mu_1 = \mu_2$	$\mu_1 \neq \mu_2$	$T = \dfrac{\overline{x} - \overline{y}}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$	$\lvert T\rvert > t_{1-\alpha/2}(\nu = \min(n_1, n_2) - 1)$
	$\mu_1 > \mu_2$		$T > t_{1-\alpha}(\nu = \min(n_1, n_2) - 1)$
	$\mu_1 < \mu_2$		$T < -t_{1-\alpha}(\nu = \min(n_1, n_2) - 1)$

10.4.2 Test o shodě rozptylů - F-test

Pokud $X_1, X_2, \ldots, X_{n_1}$ je náhodný výběr z normálního rozdělení $N(\mu_1, \sigma_1^2)$ a $Y_1, Y_2, \ldots, Y_{n_2}$ je na něm nezávislý náhodný výběr z normálního rozdělení $N(\mu_2, \sigma_2^2)$

nulová hypotéza H_0	alternativní H_1	testová statistika T	kritický obor $T \in W$
$\sigma_1^2 = \sigma_2^2$	$\sigma_1^2 \neq \sigma_2^2$	$F = s_1^2/s_2^2$	$F \notin \big(F_{\alpha/2}; F_{1-\alpha/2}(\nu_1 = n_1 - 1, \nu_2 = n_2 - 1)\big)$
	$\sigma_1^2 > \sigma_2^2$		$F > F_{1-\alpha}(\nu_1 = n_1 - 1, \nu_2 = n_2 - 1)$
	$\sigma_1^2 < \sigma_2^2$		$F < F_{\alpha}(\nu_1 = n_1 - 1, \nu_2 = n_2 - 1)$

10.4.3 Test o koeficientu korelace (lineární závislosti)

Pro dvě náhodné veličiny X a Y lze lineární vazbu vyjádřit pomocí kovariance

$$\operatorname{cov}(X, Y) = \mathbb{E}\left((X - \mathbb{E}X) \cdot (Y - \mathbb{E}Y)\right) = \mathbb{E}\left(X \cdot Y\right) - \mathbb{E}\left(X\right) \cdot \mathbb{E}\left(Y\right)$$

nebo korelace

$$\operatorname{cor}(X, Y) = \rho = \frac{\operatorname{cov}(X, Y)}{\sqrt{\mathrm{var[X]} \cdot \mathrm{var[Y]}}}.$$

Definice 10.2 (Pearsonův koeficient korelace)**.** *Pokud $(X_1, Y_1), (X_2, Y_2) \ldots, (X_n, Y_n)$ je náhodný výběr z nějakého dvourozměrného rozdělení, pak Pearsonův koeficient korelace je definován vztahem*

$$r = \frac{\sum_{i=1}^{n}(X_i - \overline{X})(Y_i - \overline{Y})}{\sqrt{\sum_{i=1}^{n}(X_i - \overline{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i - \overline{Y})^2}},$$

kde $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ je aritmetický průměr prvních měření a $\overline{Y}$ je aritmetický průměr druhých měření.
Ekvivalentně lze Pearsonův korelační koeficient vyjádřit pomocí součinů z-skórů

$$r = \frac{1}{n-1} \sum_{i=1}^{n} \left(\frac{X_i - \overline{X}}{s_X} \right) \left(\frac{Y_i - \overline{Y}}{s_Y} \right),$$

kde $s_X = \sqrt{\frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X})^2}$ *je směrodatná odchylka (standard deviation, SD) prvního výběru,* s_Y *směrodatná odchylka druhého výběru.*

V případě, kdy jeden ze znaků je binární (např. sledujeme-li závislost binární položky Y a celkového počtu bodů X, tzv. index RIT), se korelační koeficient redukuje na tzv. bodově-biseriální korelační koeficient

$$r_{bis} = \frac{\bar{X}_1 - \bar{X}_0}{s} \frac{n_0 n_1}{n(n-1)},$$

kde $\bar{X}_1$ je průměr celkového počtu bodů těch studentů, kteří mají hodnotu sledované položky rovnou 1, $\bar{X}_0$ je průměr celkového počtu bodů těch studentů, kteří mají hodnotu sledované položky rovnou 0, s^2 je směrodatná odchylka celkových bodových zisků, n_1 je počet jedniček a n_0 je počet nul.

Pokud $(X_1, Y_1), (X_2, Y_2) \ldots, (X_n, Y_n)$ je náhodný výběr z dvourozměrného normálního rozdělení, kde korelační koeficient $\rho = 0$

nulová hypotéza	alternativní	testová statistika	kritický obor
H_0	H_1	T	$T \in W$
	$\rho \neq 0$		$\lvert R \rvert > t_{1-\alpha/2}(\nu = n-2)$
$\rho = 0$	$\rho > 0$	$R = \frac{r}{\sqrt{1-r^2}} \sqrt{n-2}$	$R > t_{1-\alpha}(\nu = n-2)$
	$\rho < 0$		$R < -t_{1-\alpha}(\nu = n-2)$

10.5 Testování shody dat s modelem

10.5.1 χ^2 test dobré shody

H_0 pravděpodobnosti výsledků jsou $p_1, p_2, \ldots, p_k$ (data mají rozdělení daná těmito ppstmi)
Porovnáváme očekávané četnosti $n_i^O > 5$ určené pomocí ppsti p_i a naměřené četnosti n_i
Postup je následující:

- Rozdělíme obor hodnot náhodné veličiny X na k nepřekrývajících se tříd.
- Zjistíme, kolik hodnot realizovaného náhodného výběru se nachází v jednotlivých třídách. Počty prvků v jednotlivých třídách označíme n_i
- Pokud je $m > 0$ parametrů rozdělení neznámých, tak je odhadneme (k dispozici máme tedy po tomto kroku pravděpodobnosti p_i dané tímto rozdělením).
- Pro každou třídu spočteme očekávaný počet hodnot v této třídě, ozn. n_i^O. Platí $n_i^O = np_i$.
- V případě, že je v některé třídě počet očekávaných hodnot menší než 5, pak musíme tuto třídu sdružit s jinou.

- Testovací statistika má tvar
$$\chi^2 = \sum_{i=1}^{k} \frac{(n_i - n_i^O)^2}{n_i^O}$$
- Testovací statistika má za platnosti nulové hypotézy asymptoticky χ^2-rozdělení se stupněm volnosti $\nu = k - 1 - m$.
- Hypotézu, že se náhodná veličina řídí předpokládaným modelem, zamítáme na hladině významnosti α, je-li
$$\chi^2 > \chi^2_{1-\alpha}(\nu),$$
kde $\chi^2_{1-\alpha}(\nu)$ je kvantil χ^2 rozdělení s volností $\nu = k - 1 - m$.

10.5.2 Kontingenční tabulky. Testování nezávislosti

Testujeme nezávislost dvou náhodných veličin X a Y, pro které máme k dispozici údaje o četnostech n_{ij} obsažené v kontingenční tabulce.

	y_1	y_2	$\dots$	y_J	součty
x_1	n_{11}	n_{12}	$\dots$	n_{1J}	$n_{1.}$
x_2	n_{21}	n_{22}	$\dots$	n_{2J}	$n_{2.}$
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$n_{2.}$
x_I	n_{I1}	n_{I2}	$\dots$	n_{IJ}	$n_{I.}$
součty	$n_{.1}$	$n_{.2}$	$\dots$	$n_{.J}$	n

Při platnosti nezávislosti lze očekávané četnosti vypočíst podle vztahu (požadujeme, aby očekávané četnosti $n_i^O > 5$)
$$n_{ij}^O = \frac{n_{i.}n_{.j}}{n}$$
Testovací statistika má tvar:
$$\chi^2 = \sum_{i=1}^{I} \sum_{j=1}^{J} \frac{(n_{ij} - n_{ij}^O)^2}{n_{ij}^O}$$
Testovací statistika má za platnosti nulové hypotézy (nezávislost obou veličin) asymptoticky χ^2-rozdělení se stupněm volnosti $\nu = (I-1)(J-1)$.

Hypotézu, že se náhodné veličiny jsou nezávislé, zamítáme na hladině významnosti α, je-li
$$\chi^2 > \chi^2_{1-\alpha}(\nu),$$
kde $\chi^2_{1-\alpha}(\nu)$ je kvantil χ^2 rozdělení s volností $\nu = (I-1)(J-1)$.

11 Regresní analýza

11.1 Lineární regresní model

Zjišťujeme, zda hodnoty Y (vysvětlovaná proměnná) závisí na hodnotě x (vysvětlující proměnná). Uvažujeme model $Y = f(\beta_0, \beta_1, \ldots, \beta_k; x) + \varepsilon$,

kde $\varepsilon \sim N(0, \sigma^2)$ representuje nesystematické chyby.

Model odhadujeme na základě sady měření $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$.

Příklady lineárních modelů

$Y = \beta_0 + \beta_1 x + \varepsilon$	lineární model
$Y = \beta_0 + \beta_1 \ln(x) + \varepsilon$	logaritmický model
$Y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$	polynomiální stupně 2
$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon$	modely s více vysvětlujícími proměnnými

Příklady nelineárních modelů

$Y = \beta_0 \cdot e^{\beta_1 x} + \varepsilon$	exponenciální model
$Y = \beta_0 \cdot x^{\beta_1} + \varepsilon$	mocninný

Maticový zápis lineárního regresního modelu

$$\begin{bmatrix} Y_1 \\ Y_2 \\ \\ \vdots \\ \\ Y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & \ldots & x_{1k} \\ 1 & x_{21} & \ldots & x_{2k} \\ \\ \vdots & \vdots & \ddots & \vdots \\ \\ 1 & x_{n1} & \ldots & x_{nk} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \\ \vdots \\ \\ \varepsilon_n \end{bmatrix},$$

kde

- $\boldsymbol{Y} = [Y_1, Y_2, \ldots, Y_n]^T$ je vektor vysvětlované proměnné;
- $\boldsymbol{X}$ je matice typu $n \times (k+1)$ hodnot vysvětlujících proměnných nazývaná regresní matice, matice modelu nebo matice plánu, počet sloupců matice budeme značit p a platí $p = k + 1$;
- $\boldsymbol{\beta} = [\beta_0, \beta_1, \ldots, \beta_k]^T$ je vektor hledaných $k + 1$ neznámých parametrů;
- $\boldsymbol{\varepsilon} = [\varepsilon_1, \varepsilon_2, \ldots, \varepsilon_n]^T$ je vektor náhodné složky.

Předpoklady regresního modelu a normálního regresního modelu

(P1) $\mathbb{E}(\varepsilon_i) = 0$ pro všechny $i = 1, 2, \ldots, n$

(P2) $\operatorname{var}(\varepsilon_i) = \sigma^2$ (homoskedasticita) a $\operatorname{cov}(\varepsilon_i, \varepsilon_j) = 0$ pro $i \neq j$ (nekorelovanost)

(*P1+P2) $\boldsymbol{\varepsilon} \sim N(\boldsymbol{0}; \sigma^2 \boldsymbol{I}_n)$

(P3) neexistuje přesná lineární vazba mezi sloupci matice, matice $\boldsymbol{X}$ má plnou hodnost

(P4) $\boldsymbol{X}$ je nestochastická

11.2 Metoda nejmenších čtverců

Parametry modelu $\beta_0, \beta_1, \ldots, \beta_k$ lze odhadnout například metodou nejmenších čtverců, která minimalizuje výraz $S(\beta_0, \beta_1, \ldots, \beta_k) = \sum_{i=1}^{n} (y_i - f(\beta_0, \beta_1, \ldots, \beta_k; x_i))^2$

Věta 11.1 (Gaussova Markovova věta)**.** *Uvažujme lineární regresní model v maticovém tvaru* $\boldsymbol{Y} = \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ *s předpoklady (P1)-(P4). Pak*

(i) odhad parametrů metodou nejmenších čtverců má tvar $\boldsymbol{b} = \left(\boldsymbol{X}^T\boldsymbol{X}\right)^{-1}\boldsymbol{X}^T\boldsymbol{Y}$*;*

(ii) $\boldsymbol{b}$ *je nestranným odhadem* $\boldsymbol{\beta}$ *(tj.* $\mathbb{E}(\boldsymbol{b}) = \boldsymbol{\beta}$*) a* $\operatorname{var}(\boldsymbol{b}) = \sigma^2\left(\boldsymbol{X}^T\boldsymbol{X}\right)^{-1}$*;*

(iii) $s_R^2 = \dfrac{RSE}{n-k-1}$ *je nestranným odhadem* σ^2*, (tj.* $\mathbb{E}\left(s_R^2\right) = \sigma^2$*)*

kde $RSE = (\boldsymbol{Y} - \boldsymbol{X}\boldsymbol{b})^T(\boldsymbol{Y} - \boldsymbol{X}\boldsymbol{b})$ *je reziduální součet čtverců odchylek;*

Věta 11.2 (Gaussova Markovova věta s předpokladem normality)**.** *Uvažujme lineární regresní normální model v maticovém tvaru* $\boldsymbol{Y} = \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ *s předpoklady (*P1+P2)-(P4). Pak*

(i) $\boldsymbol{b} \sim N\left(\boldsymbol{\beta}; \sigma^2\left(\boldsymbol{X}^T\boldsymbol{X}\right)^{-1}\right)$*;*

(ii) $\dfrac{RSE}{\sigma^2} = \dfrac{s_R^2(n-k-1)}{\sigma^2} \sim \chi^2$ *se stupni volnosti* $\nu = n-k-1$

(iii) Pro $j = 0, 1, \ldots, k$ *platí* $\frac{b_j - \beta_j}{\sqrt{s_R^2 \cdot diag_j(X^TX)^{-1}}} \sim t(\nu = n-k-1)$*, kde* $diag_j(X^TX)^{-1}$ *je prvek na pozici* jj *matice* $\left(\boldsymbol{X}^T\boldsymbol{X}\right)^{-1}$*.*

Definice 11.3. *Pro lineární regresní model označme*

TSS = $\sum_i (y_i - \overline{y})^2$ *(celkový součet čtverců - total sum of squares)*

celkový rozptyl $s_T^2 = \frac{TSE}{n-1}$ *(total variance, total mean square)*

ESS = $\sum_i (\widehat{y_i} - \overline{y})^2$ *(vysvětlený součet čtverců - explained sum of squares)*

regresní rozptyl $s_E^2 = \frac{ESS}{k}$ *(regression mean square)*

RSE = $\sum_i (y_i - \widehat{y_i})^2$ *(reziduální součet čtverců odchylek - residual sum of squares errors)*

residuální rozptyl $s_R^2 = \frac{RSE}{n-k-1}$ *(residual mean square)*

Věta 11.4. *Pro lineární regresní model platí* $TSS = ESS + RSE$*.*

Definice 11.5. *Koeficient determinace je dán vztahem*

$$R^2 = 1 - \frac{RSE}{TSS}$$

a upravený koeficient determinace (adjusted) je dán vztahem

$$R_a^2 = 1 - \frac{RSE/(n-k-1)}{TSS/(n-1)}.$$

Věta 11.6. *Pro koeficient determinace platí*

(i) $R^2 = \frac{ESS}{TSS} = \frac{s_E^2(k)}{s_T^2(n-1)} = 1 - \frac{s_R^2(n-k-1)}{s_T^2(n-1)}$

(ii) $0 \leq R^2 \leq 1$

(iii) *pro* $k = 1$ *(přímková regrese) platí* $\sqrt{R^2} = |r|$, *kde* r *je výběrový korelační koeficient*

$$r = \frac{s_{xy}}{s_x \cdot s_y} = \frac{\sum_{i=1}^n (x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_{i=1}^n (x_i - \overline{x})^2}\sqrt{\sum_{i=1}^n (y_i - \overline{y})^2}}$$

a pro upravený koeficient determinace platí $R_a^2 = 1 - \frac{s_R^2}{s_T^2}$

11.3 Testy pro lineární regresní modely

Pro **test významnosti regrese**, kde $H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0$ ver. H_1 : alespoň jeden koeficient je nenulový se využije testová statistika

$$F = \frac{s_E^2}{s_R^2} = \frac{ESS/(k)}{RSE/(n-k-1)} = \frac{R^2}{1-R^2}\frac{n-k-1}{k}$$

kde $F|_{H_0} \sim F(\nu_1 = k, \nu_2 = n-k-1)$ (Fisherovo rozdělení).

Pro **test významnosti pro jednotlivé koeficienty**, kde $H_0 : \beta_j = 0$ ver. $H_1 : \beta_j \neq 0$ se využije testová statistika

$$t = \frac{b_j}{se(b_j)},$$

kde $se(b_j)$ je směrodatná odchylka odhadu koeficientu a počítá se vztahem

$$se(b_j) = \sqrt{s_R^2 \cdot diag_j(X^T X)^{-1}}$$

a platí $t|_{H_0} \sim t(\nu = n-k-1)$.